

# Previsão do MAPE em modelos de metano entérico

IME0546 — Tópicos em Matemática Aplicada · Rede Global de Nutrição Animal (treino)

Relatório consolidado das fases 01–05

02/09/2026

TÓPICOS

1 Problema e recorte

1.1 O que o case pede

1.2 Unidade de análise

2 Dicionário e integridade

3 O alvo (MAPE)

3.1 Forma da distribuição

3.2 Desempenho global dos cinco modelos empíricos

3.3 Quem vence animal a animal (Top-1 observado)

4 Covariáveis do animal

4.1 Contínuas (um registro por animal)

4.2 Status metabólico

4.3 Sexo

5 Geografia: países e estudos

5.1 Tamanho amostral por país

5.2 Mediana país × modelo

5.3 Fração de vitórias (Top-1) nos cinco países do case

6 Variância entre estudos

7 Engenharia de features (fase 03)

8 Validação e modelos (fases 04–05)

8.1 Protocolo

9 Apostas do case (teste lacrado)

10 Limitações

11 O que fica amarrado

Este documento reúne a exploração, as hipóteses do case e o desenho de modelagem sobre o **conjunto de treino** (`dados_treino.xlsx`). O arquivo de teste permanece **lacrado**: nenhuma decisão abaixo usa `dados_teste.xlsx`.

O objeto de previsão **não** é a emissão de metano. Para cada animal, cinco modelos empíricos (`Modelo_1` ... `Modelo_5`) já tentaram prever essa emissão; o que a planilha registra é o **MAPE** (erro percentual absoluto médio) de cada tentativa. Quanto menor o MAPE, melhor aquele modelo empírico foi naquela observação.

## 1 Problema e recorte

### 1.1 O que o case pede

A base mascarada da Rede Global de Nutrição Animal reúne estudos de confinamento em 16 países. Cinco países tiveram **um estudo inteiro** retirado do treino (Campo Rico, Ilha Verdejante, Terra Nortenha, Monção Dourada, Costa Austral). Esse estudo só existe no teste.

Perguntas do enunciado, a responder **antes** de abrir o teste:

1. Existe um modelo empírico melhor na maioria dos países, ou o campeão muda?

2. Sexo, status metabólico e peso se relacionam com quem erra menos?

3. Qual modelo apostaríamos no estudo oculto de cada um dos cinco países?

Há ainda o horizonte da **competição da disciplina**: um modelo nosso que, para cada linha, preveja o MAPE contínuo. São dois alvos:

| SUPERFÍCIE | PERGUNTA                                              | MÉTRICA          |
|------------|-------------------------------------------------------|------------------|
| Case       | Qual dos cinco empíricos errará menos no estudo novo? | Ranking / Top-1  |
| Competição | Qual o valor do MAPE daquela linha?                   | MAE, RMSE, $R^2$ |

Acertar o número do MAPE não garante acertar **quem** é o melhor dos cinco no mesmo animal. Por isso o relatório trata os dois.

### 1.2 Unidade de análise

Cada linha é o par (animal, modelo empírico). Os cinco MAPes do mesmo ID\_Observacao são **dependentes**. Animais do mesmo Estudo compartilham protocolo, dieta e país. Cortar treino/validação por linha (ou só por animal) vaza informação que o teste real não terá: lá some um estudo completo.

## 2 Dicionário e integridade

| COLUNA                          | PAPEL NESTE TRABALHO                                                         |
|---------------------------------|------------------------------------------------------------------------------|
| ID_Observacao                   | Animal. Cinco linhas compartilham o mesmo ID.                                |
| Estudo                          | Grupo de validação. <b>Não</b> entra como preditor (estudos novos no teste). |
| País_Estudo                     | Pode entrar: os cinco países do case <b>existem</b> no treino.               |
| Sistema_Producao                | Enunciado: só confinamento nesta base.                                       |
| Status_Metabolico               | Crescimento, Terminação, Maduro, Crescimento e Terminação.                   |
| Sexo_Animal                     | Boi, Vaca, Novilho, Novilha, Touro, Não especificado.                        |
| Peso_Corporal_kg, Consumo_MS_kg | Covariáveis contínuas do animal.                                             |
| Fracao_Perda_A, Fracao_Perda_B  | Frações de energia perdida como metano.                                      |
| Modelo                          | Qual dos cinco empíricos gerou aquele MAPE.                                  |
| MAPE                            | Alvo. Estritamente positivo no treino.                                       |

Estrutura das colunas usadas na análise (colunas vazias da planilha original foram descartadas na leitura).

| COLUNA            | TIPO      | NULOS | VALORES DISTINTOS |
|-------------------|-----------|-------|-------------------|
| ID_Observacao     | numeric   | 0     | 223               |
| Estudo            | character | 0     | 93                |
| Pais_Estudo       | character | 0     | 16                |
| Sistema_Producao  | character | 0     | 1                 |
| Status_Metabolico | character | 0     | 4                 |
| Sexo_Animal       | character | 0     | 6                 |
| Peso_Corporal_kg  | numeric   | 0     | 127               |
| Consumo_MS_kg     | numeric   | 0     | 166               |
| Fracao_Perda_A    | numeric   | 0     | 206               |
| Fracao_Perda_B    | numeric   | 0     | 206               |
| Modelo            | factor    | 0     | 5                 |
| MAPE              | numeric   | 0     | 1106              |

Contagens: 1115 linhas, 223 animais, 93 estudos, 16 países, 5 modelos. Mínimo e máximo de linhas por ID: 5 e 5 (sempre 5).

Sistema\_Producao é só **Confinamento**. A coluna é constante; **não entra no modelo**. Na pecuária real existem outros sistemas (por exemplo terminação a pasto); este recorte foi filtrado de propósito, não é falha de dicionário.


Correlação de Fracao\_Perda\_A com Fracao\_Perda\_B: 1,000000. No treino as duas séries são indistinguíveis. Na engenharia de features permanece uma delas.

### 3 O alvo (MAPE)

3.1 Forma da distribuição

Distribuição do MAPE

Média 0,229 · mediana 0,186 · assimetria 1,61



Fonte: dados\_treino.xlsx. Treino apenas.


Histograma do MAPE no treino (1.115 linhas). A linha tracejada é a mediana.

Resumo univariado do MAPE no treino.

| N    | MEDIA | MEDIANA | DESVIO | Q 1   | Q 3   | MINIMO | MAXIMO | ASSIMETRIA | N_NAO_POSITIVO |
|------|-------|---------|--------|-------|-------|--------|--------|------------|----------------|
| 1115 | 0,229 | 0,186   | 0,192  | 0,085 | 0,315 | 0,000  | 1,214  | 1,609      | 0              |

A média (0,229) está acima da mediana (0,186): cauda direita. O máximo (1,214) ultrapassa 100% de erro percentual. Não há  $MAPE \leq 0$ ;  $\ln(MAPE)$  é definido, mas qualquer modelo treinado no log tem de **inverter** antes da métrica da competição, que é na escala original.

### Densidade do MAPE por modelo



Modelo  Modelo\_1  Modelo\_2  Modelo\_3  Modelo\_4  Modelo\_5

Fonte: dados\_treino.xlsx. Kernel gaussiano.


Densidade do MAPE por modelo empírico. A cauda longa é comum aos cinco; o centro de massa não.

## 3.2 Desempenho global dos cinco modelos empíricos

O **baseline** da metodologia é o modelo com **menor mediana** de MAPE no treino. Por esse critério o campeão é **Modelo\_4**. Pela **média**, o menor valor é o de **Modelo\_5**: o Modelo\_5 sofre menos com extremos, o Modelo\_4 ganha no centro da distribuição. A métrica de desempate combinada foi a mediana, mais robusta à cauda.

## MAPE por modelo empírico

Traço interno = mediana; pontos = observações fora de 1,5×IIQ



Fonte: dados\_treino.xlsx.

Boxplot do MAPE por modelo empírico (n = 223 por modelo).

MAPE por modelo empírico, ordenado pela mediana.

| MODELO   | N   | MÉDIA | MEDIANA | DESVIO | Q1    | Q3    | MÍN.  | MÁX.  |
|----------|-----|-------|---------|--------|-------|-------|-------|-------|
| Modelo_4 | 223 | 0,226 | 0,156   | 0,238  | 0,067 | 0,277 | 0,000 | 1,214 |
| Modelo_3 | 223 | 0,227 | 0,165   | 0,199  | 0,088 | 0,311 | 0,001 | 1,010 |
| Modelo_5 | 223 | 0,214 | 0,182   | 0,170  | 0,075 | 0,294 | 0,002 | 0,873 |
| Modelo_1 | 223 | 0,242 | 0,220   | 0,184  | 0,097 | 0,336 | 0,002 | 0,914 |
| Modelo_2 | 223 | 0,238 | 0,226   | 0,159  | 0,112 | 0,328 | 0,011 | 0,834 |

Como os cinco MAPEs são do **mesmo** animal, o teste adequado de diferença entre modelos é o de Friedman (blocos = ID\_Observacao): estatística  $\chi^2 = 33,28$ , gl = 4,  $p = < 0,001$ . Rejeita-se a hipótese de que os cinco tenham a mesma distribuição de MAPE.

### 3.3 Quem vence animal a animal (Top-1 observado)

Para cada ID, o “vencedor” é o modelo de menor MAPE **real**. Empates foram quebrados pela primeira ocorrência (slice\_min(..., with\_ties = FALSE)); no treino o total de vitórias soma 223, ou seja, não houve empate residual nesse critério.

Quantas vezes cada modelo empírico tem o menor MAPE no animal.

| MODELO   | VITÓRIAS | FRAÇÃO DOS ANIMAIS |
|----------|----------|--------------------|
| Modelo_4 | 89       | 39,9%              |
| Modelo_3 | 38       | 17,0%              |
| Modelo_2 | 35       | 15,7%              |
| Modelo_5 | 35       | 15,7%              |
| Modelo_1 | 26       | 11,7%              |

O Modelo\_4 vence em 39,9% dos animais — é o mais frequente, mas **não** é maioria absoluta. Há nicho real para os outros quatro.

## 4 Covariáveis do animal

### 4.1 Contínuas (um registro por animal)

Resumo das covariáveis contínuas (223 animais).


| VARIÁVEL         | N   | MÉDIA   | MEDIANA | DESVIO  | MÍN.   | MÁX.    |
|------------------|-----|---------|---------|---------|--------|---------|
| Consumo_MS_kg    | 223 | 8,363   | 8,600   | 2,698   | 2,750  | 20,000  |
| Fracao_Perda_A   | 223 | 0,021   | 0,020   | 0,006   | 0,009  | 0,047   |
| Fracao_Perda_B   | 223 | 0,021   | 0,020   | 0,006   | 0,009  | 0,047   |
| Peso_Corporal_kg | 223 | 421,755 | 397,000 | 133,418 | 98,000 | 725,000 |

Peso e consumo correlacionam entre si (0,53), o que é esperado zootecnicamente. Com o MAPE, as correlações de Pearson são fracas: peso -0,084, consumo 0,009, fração A 0,107. Sozinhas, essas variáveis não “explicam” o erro; ainda assim podem importar **em interação com o modelo empírico**.

Correlação de Pearson (linhas do treino, n = 1.115).

|                  | MAPE   | PESO_CORPORAL_KG | CONSUMO_MS_KG | FRACAO_PERDA_A | FRACAO_PERDA_B |
|------------------|--------|------------------|---------------|----------------|----------------|
| MAPE             | 1,000  | -0,084           | 0,009         | 0,107          | 0,107          |
| Peso_Corporal_kg | -0,084 | 1,000            | 0,526         | -0,453         | -0,453         |
| Consumo_MS_kg    | 0,009  | 0,526            | 1,000         | 0,457          | 0,457          |
| Fracao_Perda_A   | 0,107  | -0,453           | 0,457         | 1,000          | 1,000          |
| Fracao_Perda_B   | 0,107  | -0,453           | 0,457         | 1,000          | 1,000          |


## MAPE vs peso corporal



Fonte: dados\_treino.xlsx. Um ponto por linha (animal × modelo).

MAPE contra peso corporal, por modelo. A nuvem é dispersa: não há reta óbvia.


## MAPE vs consumo de matéria seca



Fonte: dados\_treino.xlsx.

MAPE contra consumo de matéria seca, por modelo.

## MAPE vs Fracao\_Perda\_A



Fonte: dados\_treino.xlsx.

MAPE contra Fracao\_Perda\_A, por modelo.

A taxa Consumo\_MS\_kg / Peso\_Corporal\_kg entra depois como feature zootécnica (consumo relativo ao peso).

## 4.2 Status metabólico

Kruskal-Wallis do MAPE entre status (ignorando o pareamento por modelo):  $p = 0,001$ . O nível de erro não é o mesmo nas fases produtivas, mas o que o case pergunta é se o **vencedor** muda.

Modelo de menor mediana de MAPE em cada status metabólico.


| STATUS                   | VENCEDOR (MEDIANA) | N   | MÉDIA | MEDIANA |
|--------------------------|--------------------|-----|-------|---------|
| Crescimento              | Modelo_3           | 113 | 0,242 | 0,158   |
| Crescimento e Terminação | Modelo_3           | 8   | 0,075 | 0,066   |
| Maturo                   | Modelo_3           | 17  | 0,141 | 0,135   |
| Terminação               | Modelo_4           | 85  | 0,210 | 0,142   |

MAPE completo: status x modelo.

| STATUS                   | MODELO   | N   | MÉDIA | MEDIANA |
|--------------------------|----------|-----|-------|---------|
| Crescimento              | Modelo_3 | 113 | 0,242 | 0,158   |
| Crescimento              | Modelo_5 | 113 | 0,217 | 0,163   |
| Crescimento              | Modelo_4 | 113 | 0,256 | 0,180   |
| Crescimento              | Modelo_1 | 113 | 0,248 | 0,214   |
| Crescimento              | Modelo_2 | 113 | 0,250 | 0,234   |
| Crescimento e Terminação | Modelo_3 | 8   | 0,075 | 0,066   |
| Crescimento e Terminação | Modelo_5 | 8   | 0,099 | 0,091   |
| Crescimento e Terminação | Modelo_1 | 8   | 0,108 | 0,097   |
| Crescimento e Terminação | Modelo_4 | 8   | 0,161 | 0,183   |
| Crescimento e Terminação | Modelo_2 | 8   | 0,215 | 0,207   |
| Maturo                   | Modelo_3 | 17  | 0,141 | 0,135   |
| Maturo                   | Modelo_5 | 17  | 0,161 | 0,135   |
| Maturo                   | Modelo_4 | 17  | 0,146 | 0,157   |
| Maturo                   | Modelo_1 | 17  | 0,187 | 0,185   |
| Maturo                   | Modelo_2 | 17  | 0,241 | 0,266   |
| Terminação               | Modelo_4 | 85  | 0,210 | 0,142   |
| Terminação               | Modelo_2 | 85  | 0,224 | 0,174   |
| Terminação               | Modelo_3 | 85  | 0,237 | 0,210   |
| Terminação               | Modelo_5 | 85  | 0,229 | 0,210   |
| Terminação               | Modelo_1 | 85  | 0,257 | 0,241   |

Crescimento (n = 113 animais) favorece o **Modelo\_3** na mediana. Terminação favorece o **Modelo\_4**. “Crescimento e Terminação” e Maturo têm n pequeno (8 e 17 animais): o vencedor local é instável.

MAPE segundo o status metabólico



Fonte: dados\_treino.xlsx.

Distribuição do MAPE por status, um painel por modelo empírico.

4.3 Sexo

Kruskal-Wallis:  $p = < 0,001$ .

Tamanho amostral por sexo (um registro por animal).


| SEXO             | ANIMAIS |
|------------------|---------|
| Boi              | 136     |
| Novilho          | 44      |
| Novilha          | 22      |
| Vaca             | 13      |
| Não especificado | 4       |
| Touro            | 4       |

Boi concentra 136/223 animais. Touro e Não especificado têm 4 animais cada: qualquer “nicho” nessas células é ruído.

Modelo de menor mediana de MAPE em cada sexo.

| SEXO             | VENCEDOR (MEDIANA) | N LINHAS | MÉDIA | MEDIANA |
|------------------|--------------------|----------|-------|---------|
| Boi              | Modelo_4           | 136      | 0,249 | 0,148   |
| Novilha          | Modelo_4           | 22       | 0,172 | 0,159   |
| Novilho          | Modelo_5           | 44       | 0,173 | 0,124   |
| Não especificado | Modelo_3           | 4        | 0,149 | 0,146   |
| Touro            | Modelo_4           | 4        | 0,081 | 0,041   |
| Vaca             | Modelo_4           | 13       | 0,140 | 0,050   |

MAPE segundo o sexo



Fonte: dados\_treino.xlsx.

MAPE por sexo do animal, facetas por modelo empírico.

Novilho puxa o **Modelo\_5**; Boi, Vaca e Novilha, o **Modelo\_4**. Isso reforça a necessidade de interação **Modelo** × características, e também o risco de overfit se o encoding de sexo for ingênuo nas classes raras.

## 5 Geografia: países e estudos

Kruskal–Wallis do MAPE entre países:  $p = < 0,001$ . O nível de erro **não** é o mesmo em todo lugar.


### 5.1 Tamanho amostral por país

Grandvale sozinho tem **90** dos 223 animais (cerca de 40,4%). O campeão global é, em boa parte, o campeão de Grandvale. Países com 2–3 animais não sustentam uma aposta estável.

Cobertura do treino por país. Os cinco do case não são os menores.

| PAÍS                | ESTUDOS NO TREINO | ANIMAIS | LINHAS |
|---------------------|-------------------|---------|--------|
| Grandvale           | 33                | 90      | 450    |
| Campo Rico          | 14                | 25      | 125    |
| Reino Litoral       | 4                 | 17      | 85     |
| Ilha Verdejante     | 9                 | 16      | 80     |
| Monção Dourada      | 5                 | 12      | 60     |
| Planalto Sol        | 4                 | 12      | 60     |
| Terra Nortenha      | 6                 | 12      | 60     |
| Costa Austral       | 4                 | 10      | 50     |
| Arquipélago Oriente | 3                 | 7       | 35     |
| Vale do Indus Novo  | 4                 | 6       | 30     |
| Península Matina    | 2                 | 5       | 25     |
| Ilhota Central      | 1                 | 3       | 15     |
| Alpes Neutros       | 1                 | 2       | 10     |
| Baixo Reino         | 1                 | 2       | 10     |
| Império Central     | 1                 | 2       | 10     |
| Terra do Galo       | 1                 | 2       | 10     |

5.2 Mediana país × modelo



Mediana do MAPE por país e modelo. Células escuras = erro maior. Países ordenados pela melhor mediana entre os cinco.

Vencedor por mediana em cada país (treino). Estudos e animais restantes naquele país.

| PAÍS                | VENCEDOR | MEDIANA | ESTUDOS | ANIMAIS |
|---------------------|----------|---------|---------|---------|
| Alpes Neutros       | Modelo_1 | 0,210   | 1       | 2       |
| Arquipélago Oriente | Modelo_1 | 0,118   | 3       | 7       |
| Baixo Reino         | Modelo_4 | 0,204   | 1       | 2       |
| Campo Rico          | Modelo_1 | 0,094   | 14      | 25      |
| Costa Austral       | Modelo_4 | 0,127   | 4       | 10      |
| Grandvale           | Modelo_4 | 0,155   | 33      | 90      |
| Ilha Verdejante     | Modelo_4 | 0,087   | 9       | 16      |
| Ilhota Central      | Modelo_3 | 0,023   | 1       | 3       |
| Império Central     | Modelo_3 | 0,123   | 1       | 2       |
| Monção Dourada      | Modelo_3 | 0,145   | 5       | 12      |
| Península Matina    | Modelo_5 | 0,067   | 2       | 5       |
| Planalto Sol        | Modelo_3 | 0,151   | 4       | 12      |
| Reino Litoral       | Modelo_4 | 0,091   | 4       | 17      |
| Terra Nortenha      | Modelo_4 | 0,134   | 6       | 12      |
| Terra do Galo       | Modelo_4 | 0,214   | 1       | 2       |
| Vale do Indus Novo  | Modelo_5 | 0,185   | 4       | 6       |

O vencedor local **não** é único: aparecem Modelo\_1, 3, 4 e 5. A resposta à primeira pergunta do case é: **o campeão muda de país para país**.

### 5.3 Fração de vitórias (Top-1) nos cinco países do case

A mediana e o Top-1 podem discordar. Campo Rico é o exemplo: a mediana favorece o Modelo\_1, mas a fração de vitórias favorece o Modelo\_5.

Top-1 observado nos animais do treino, só nos cinco países com estudo oculto.

| PAÍS            | MODELO   | VITÓRIAS | FRAÇÃO |
|-----------------|----------|----------|--------|
| Campo Rico      | Modelo_1 | 5        | 20%    |
| Campo Rico      | Modelo_2 | 6        | 24%    |
| Campo Rico      | Modelo_3 | 4        | 16%    |
| Campo Rico      | Modelo_4 | 2        | 8%     |
| Campo Rico      | Modelo_5 | 8        | 32%    |
| Costa Austral   | Modelo_1 | 1        | 10%    |
| Costa Austral   | Modelo_2 | 0        | 0%     |
| Costa Austral   | Modelo_3 | 3        | 30%    |
| Costa Austral   | Modelo_4 | 5        | 50%    |
| Costa Austral   | Modelo_5 | 1        | 10%    |
| Ilha Verdejante | Modelo_1 | 1        | 6%     |
| Ilha Verdejante | Modelo_2 | 0        | 0%     |
| Ilha Verdejante | Modelo_3 | 1        | 6%     |
| Ilha Verdejante | Modelo_4 | 13       | 81%    |
| Ilha Verdejante | Modelo_5 | 1        | 6%     |
| Monção Dourada  | Modelo_1 | 0        | 0%     |
| Monção Dourada  | Modelo_2 | 0        | 0%     |
| Monção Dourada  | Modelo_3 | 7        | 58%    |
| Monção Dourada  | Modelo_4 | 3        | 25%    |
| Monção Dourada  | Modelo_5 | 2        | 17%    |
| Terra Nortenha  | Modelo_1 | 0        | 0%     |
| Terra Nortenha  | Modelo_2 | 0        | 0%     |
| Terra Nortenha  | Modelo_3 | 2        | 17%    |
| Terra Nortenha  | Modelo_4 | 8        | 67%    |
| Terra Nortenha  | Modelo_5 | 2        | 17%    |

MAPE médio e mediano nos cinco países (estudos que restaram no treino).

| PAÍS            | MODELO   | N  | MÉDIA | MEDIANA |
|-----------------|----------|----|-------|---------|
| Campo Rico      | Modelo_1 | 25 | 0,150 | 0,094   |
| Campo Rico      | Modelo_5 | 25 | 0,134 | 0,096   |
| Campo Rico      | Modelo_3 | 25 | 0,152 | 0,098   |
| Campo Rico      | Modelo_2 | 25 | 0,175 | 0,144   |
| Campo Rico      | Modelo_4 | 25 | 0,236 | 0,209   |
| Costa Austral   | Modelo_4 | 10 | 0,141 | 0,127   |
| Costa Austral   | Modelo_3 | 10 | 0,160 | 0,128   |
| Costa Austral   | Modelo_5 | 10 | 0,179 | 0,134   |
| Costa Austral   | Modelo_1 | 10 | 0,185 | 0,165   |
| Costa Austral   | Modelo_2 | 10 | 0,251 | 0,252   |
| Ilha Verdejante | Modelo_4 | 16 | 0,113 | 0,087   |
| Ilha Verdejante | Modelo_3 | 16 | 0,203 | 0,190   |
| Ilha Verdejante | Modelo_5 | 16 | 0,210 | 0,190   |
| Ilha Verdejante | Modelo_1 | 16 | 0,257 | 0,245   |
| Ilha Verdejante | Modelo_2 | 16 | 0,310 | 0,331   |
| Monção Dourada  | Modelo_3 | 12 | 0,161 | 0,145   |
| Monção Dourada  | Modelo_4 | 12 | 0,190 | 0,215   |
| Monção Dourada  | Modelo_1 | 12 | 0,201 | 0,229   |
| Monção Dourada  | Modelo_5 | 12 | 0,180 | 0,232   |
| Monção Dourada  | Modelo_2 | 12 | 0,218 | 0,277   |
| Terra Nortenha  | Modelo_4 | 12 | 0,147 | 0,134   |
| Terra Nortenha  | Modelo_2 | 12 | 0,197 | 0,175   |
| Terra Nortenha  | Modelo_3 | 12 | 0,209 | 0,187   |
| Terra Nortenha  | Modelo_5 | 12 | 0,218 | 0,200   |
| Terra Nortenha  | Modelo_1 | 12 | 0,232 | 0,209   |

## 6 Variância entre estudos

Se o MAPE fosse i.i.d. entre linhas, K-fold simples bastaria. A ANOVA de um fator  $\text{MAPE} \sim \text{Estudo}$  decompõe a soma de quadrados:

ANOVA one-way do MAPE em Estudo.

| FONTE                       | GL   | SOMA DE QUADRADOS | FRAÇÃO DA SQ |
|-----------------------------|------|-------------------|--------------|
| Estudo                      | 92   | 23,525            | 57,4%        |
| Residual (dentro do estudo) | 1022 | 17,469            | 42,6%        |

O ICC (método dos momentos, desbalanceado) usa o  $n_0$  de Searle:

$$n_0 = \frac{N - \sum_i n_i^2/N}{k - 1}, \quad \sigma_b^2 = \max(0, (MS_E - MS_R)/n_0), \quad \widehat{ICC} = \sigma_b^2/(\sigma_b^2 + \sigma_w^2).$$

Aqui  $k = 93$  estudos,  $n_0 \approx 11,94$ ,  $\sigma_b^2 = 0,0200$ ,  $\sigma_w^2 = 0,0171$ , **ICC = 0,539**. Cerca de metade da variância do MAPE está **entre estudos**. Por isso a validação da competição tem de ser GroupKFold / leave-one-study-out, e Estudo não pode ser dummy no preditor.

Tamanho dos estudos no treino: mínimo 5 linhas, mediana 10, máximo 55 (sempre múltiplo de 5).

## 7 Engenharia de features (fase 03)

A tabela data/processed/03\_modelagem.csv é o insumo do Python. Regras aplicadas:

1. **Fora:** Sistema\_Producao (constante), Fracao\_Perda\_B (cópia de A), Estudo como *feature*.
2. **Dentro, só para cortar CV:** Estudo, ID\_Observacao.
3. **Derivada retirada:** Consumo\_sobre\_peso = Consumo\_MS\_kg / Peso\_Corporal\_kg coincidia com Fracao\_Perda\_A no treino (VIF infinito). Saiu do 03 e do 04.
4. **Consumo fora do estimador:** Consumo\_MS\_kg permanece no CSV, mas o script 04 **não** o usa (multicolinearidade biológica com peso e fração A). Os numéricos efetivos são Peso\_Corporal\_kg e Fracao\_Perda\_A (VIF  $\approx 1,26$ ).
5. **Interações em texto** (viram dummies no fold): Modelo|Status\_Metabolico, Modelo|Sexo\_Animal. Sem isso o regressor tende a aprender só o campeão global.
6. **País:** one-hot **dentro do fold**, handle\_unknown = ignore. Não usamos target encoding (vaza o alvo do grupo se for mal feito).
7. **Alvo:** pontuação na escala original do MAPE. Os regressores de ML treinam no log e reconstroem com exp; o baseline permanece na mediana bruta.

Preditores efetivos no 04: peso e fração A; categóricos país, status, sexo, modelo e as duas interações. cluster existe no CSV e não entra no estimador.

## 8 Validação e modelos (fases 04–05)

### 8.1 Protocolo

- **GroupKFold** com grupos = Estudo (cinco folds).
- **Leave-one-study-out** restrito aos estudos dos cinco países do case: imita “país já visto, estudo novo”.
- **Baseline:** mediana de MAPE daquele Modelo no fold de treino (escala original; um único estágio).
- **Regressores (OLS, splines, Ridge, Lasso, ElasticNet):** regressão em **dois estágios** no log, para não tratar as cinco linhas do mesmo animal como independentes. O estágio 1 (Ridge,  $\alpha = 10$ ) prediz o **patamar** do animal (mediana de  $\widehat{MAPE}_{log}$ , sem a coluna Modelo). O estágio 2 prediz o **resíduo relativo** de cada modelo empírico em torno desse patamar. A reconstrução é  $\widehat{MAPE} = \exp(\widehat{\text{patamar}} + \widehat{\text{resíduo}})$ . Splines: SplineTransformer só em Peso\_Corporal\_kg (4 nós, grau 3); fração A linear. Penalização: no GroupKFold,  $\alpha$  (e l1\_ratio no ElasticNet) por CV interna; no LOSO, valores padrão (Ridge  $\alpha = 10$ ; Lasso/ElasticNet  $\alpha = 0,01$ ).
- Diagnóstico de multicolinearidade: **VIF** nos numéricos usados. Incerteza do erro: **bootstrap** por estudo (IC 95% de MAE e RMSE no OOF do GroupKFold).
- Métricas: MAE, RMSE,  $R^2$  no MAPE; **Top-1** = fração de animais em que  $\arg \min_m \widehat{MAPE}_{i,m}$  acerta o empírico de menor MAPE real. A referência de ranking é **sempre o campeão do fold** (mediana local no treino).

O seletor de ML substitui “ficar com o campeão do fold” quando o Top-1 no protocolo que imita o teste (LOSO dos cinco países) é **estritamente maior**. Essa regra **foi atendida** pelo Ridge.

Média das métricas entre folds (saída de 04\_metricas\_resumo.csv).

| PROTOCOLO        | MODELO                  | N_FOLDS | MAE   | RMSE  | R2     | TOP1  | TOP1_SEMPRE_CAMPEAO |
|------------------|-------------------------|---------|-------|-------|--------|-------|---------------------|
| GroupKFold       | baseline_mediana_modelo | 5,000   | 0,140 | 0,194 | -0,079 | 0,266 | 0,266               |
| GroupKFold       | ridge                   | 5,000   | 0,145 | 0,207 | -0,227 | 0,332 | 0,266               |
| GroupKFold       | lasso                   | 5,000   | 0,146 | 0,206 | -0,225 | 0,161 | 0,266               |
| GroupKFold       | elasticnet              | 5,000   | 0,146 | 0,207 | -0,230 | 0,220 | 0,266               |
| GroupKFold       | ols                     | 5,000   | 0,147 | 0,209 | -0,257 | 0,359 | 0,266               |
| GroupKFold       | splines                 | 5,000   | 0,149 | 0,211 | -0,279 | 0,359 | 0,266               |
| LOSO_paises_case | splines                 | 38,000  | 0,115 | 0,133 | -2,590 | 0,432 | 0,439               |
| LOSO_paises_case | ols                     | 38,000  | 0,115 | 0,133 | -2,571 | 0,432 | 0,439               |
| LOSO_paises_case | ridge                   | 38,000  | 0,116 | 0,133 | -2,543 | 0,445 | 0,439               |
| LOSO_paises_case | baseline_mediana_modelo | 38,000  | 0,117 | 0,133 | -1,993 | 0,439 | 0,439               |
| LOSO_paises_case | elasticnet              | 38,000  | 0,118 | 0,136 | -2,537 | 0,355 | 0,439               |
| LOSO_paises_case | lasso                   | 38,000  | 0,120 | 0,137 | -2,584 | 0,263 | 0,439               |

VIF nos preditores numéricos (diagnóstico de multicolinearidade).


| BLOCO            | VARIAVEL         | R2_AUXILIAR | VIF  | ALERTA |
|------------------|------------------|-------------|------|--------|
| numericos_brutos | Fracao_Perda_A   | 0,20        | 1,26 | ok     |
| numericos_brutos | Peso_Corporal_kg | 0,20        | 1,26 | ok     |

IC 95% do MAE e do RMSE via bootstrap agrupado por Estudo (OOF do GroupKFold, 2000 réplicas).

| PROTOCOLO  | MODELO                  | N_BOOT   | AGRUPAMENTO | MAE   | MAE_IC95_INF | MAE_IC95_SUP | RMSE  | RMSE_IC95_INF | RMSE_IC95_SUP |
|------------|-------------------------|----------|-------------|-------|--------------|--------------|-------|---------------|---------------|
| GroupKFold | baseline_mediana_modelo | 2000,000 | Estudo      | 0,140 | 0,122        | 0,161        | 0,198 | 0,165         | 0,232         |
| GroupKFold | ridge                   | 2000,000 | Estudo      | 0,145 | 0,125        | 0,171        | 0,211 | 0,176         | 0,249         |
| GroupKFold | lasso                   | 2000,000 | Estudo      | 0,145 | 0,125        | 0,171        | 0,211 | 0,175         | 0,249         |
| GroupKFold | elasticnet              | 2000,000 | Estudo      | 0,146 | 0,126        | 0,170        | 0,211 | 0,176         | 0,248         |
| GroupKFold | ols                     | 2000,000 | Estudo      | 0,147 | 0,127        | 0,170        | 0,212 | 0,177         | 0,249         |
| GroupKFold | splines                 | 2000,000 | Estudo      | 0,149 | 0,128        | 0,173        | 0,215 | 0,178         | 0,251         |

### MAE no GroupKFold, com IC 95% bootstrap


Reamostragem por Estudo (2.000 réplicas). Barras = MAE OOF; traços = quantis 2,5% e 97,5%.



Figuras da validação (script 06\_figuras\_modelagem.R).

### MAE médio por protocolo


Média dos folds. Menor é melhor.



Figuras da validação (script 06\_figuras\_modelagem.R).

## MAE em cada pasta do GroupKFold


Cada pasta é um conjunto de estudos inteiros.



Figuras da validação (script 06\_figuras\_modelagem.R).

## MAE por pasta do GroupKFold


Cinco pontos por modelo (uma pasta = estudos inteiros). Mostra se um modelo ganha só em uma pasta.



Figuras da validação (script 06\_figuras\_modelagem.R).

## RMSE no GroupKFold, com IC 95% bootstrap


Mesma reamostragem por Estudo. Complementa o MAE (penaliza erros grandes).



Figuras da validação (script 06\_figuras\_modelagem.R).

## Top-1: seletor versus sempre o campeão do fold


Fração de animais em que o empírico de menor MAPE é acertado.



Figuras da validação (script 06\_figuras\_modelagem.R).

## VIF dos preditores numéricos


Linhas em 5 e 10. Consumo\_sobre\_peso foi retirado (coincidia com Fração A).



Figuras da validação (script 06\_figuras\_modelagem.R).

## MAPE previsto vs observado (OOF, GroupKFold)


Diagonal = previsão perfeita. Uma a cada três linhas, para leitura.



Figuras da validação (script 06\_figuras\_modelagem.R).

## Resíduo OOF (previsto – observado), GroupKFold

Positivo = o modelo superestima o MAPE. A linha é o zero.



Figuras da validação (script 06\_figuras\_modelagem.R).

**Interpretação.** Prever o **valor** do MAPE em um estudo novo continua difícil: o ICC entre estudos é alto (0,539), o  $R^2$  dos lineares é negativo e, no GroupKFold, o baseline ainda tem o menor MAE (0,140 contra 0,145–0,149 dos regressores; os ICs bootstrap se sobrepõem). Isso é o alvo da **competição** (erro contínuo).

O alvo do **case** é outro: **ranking** (qual dos cinco empíricos usar). Com a regressão em dois estágios e o VIF controlado em 1,26, o seletor de ML **superou o baseline de forma consistente** nessa métrica. No protocolo que mais se parece com o teste (LOSO\_países\_case), o **Ridge** atingiu Top-1 de **0,445** contra **0,439** do campeão do fold. No GroupKFold, **OLS e splines** atingiram **0,359**, contra **0,266** da escolha ingênua. Lasso e ElasticNet **não** repetem esse ganho de ranking (Top-1 abaixo do campeão no LOSO). A leitura operacional, portanto, não é “qualquer penalizado serve”: o seletor a levar adiante é o **Ridge em dois estágios**.

## 9 Apostas do case (teste lacrado)

O teste permanece lacrado: nenhuma aposta abaixo usa `dados_teste.xlsx`.

A mediana local no treino foi, na versão anterior do fluxo, o único critério estável. Com o Ridge em dois estágios (Top-1 0,445 no LOSO), as apostas para o estudo oculto de cada país passam a ter **duas leituras**:

1. **Baseline (conservadora)**: menor mediana de MAPE nos estudos **ainda presentes** no treino daquele país. É a tabela abaixo, registrada antes de abrir o teste.
2. **Seletor de ML (recomendado para o ranking)**: Ridge em dois estágios, usando peso corporal e fração A (e as categorias do animal) para escolher o empírico de menor MAPE previsto. Esse seletor **não** foi aplicado aos animais do arquivo de teste — o arquivo continua fechado. Ele entra na confrontação oficial, quando o teste for aberto, como desempate baseado nas covariáveis do estudo oculto (não só na história do país).

| PAÍS            | MODELO APOSTADO | MEDIANA NO TREINO | ANIMAIS NO TREINO | ESTUDOS NO TREINO |
|-----------------|-----------------|-------------------|-------------------|-------------------|
| Campo Rico      | Modelo_1        | 0,094             | 25                | 14                |
| Costa Austral   | Modelo_4        | 0,127             | 10                | 4                 |
| Ilha Verdejante | Modelo_4        | 0,087             | 16                | 9                 |
| Monção Dourada  | Modelo_3        | 0,145             | 12                | 5                 |
| Terra Nortenha  | Modelo_4        | 0,134             | 12                | 6                 |

- **Campo Rico** (14 estudos, 25 animais no treino). Único dos cinco em que a mediana aponta o **Modelo\_1**. O Top-1 observado no treino concentra-se no Modelo\_5 (32,0%). Aqui as duas leituras mais provavelmente **divergem**: a tabela conservadora fica com o 1; o Ridge, ao ver peso e fração A do estudo oculto, pode desempatar a favor do 5. Esse é o país em que o seletor mais agrega em relação à mediana.
- **Costa Austral** (4 estudos, 10 animais). **Modelo\_4**, alinhado ao global; amostra pequena.
- **Ilha Verdejante** (9 estudos, 16 animais). **Modelo\_4**, e o Top-1 local é muito concentrado nesse modelo (81,2%).
- **Monção Dourada** (5 estudos, 12 animais). **Modelo\_3**, nicho (não o campeão global); Top-1 também puxa o 3.
- **Terra Nortenha** (6 estudos, 12 animais). **Modelo\_4**, coerente com mediana e com vitórias.

A aposta pode falhar se o estudo removido for atípico em relação aos que restaram (composição de sexo/status, protocolo, cauda de MAPE). Isso é exatamente o que o case pede para discutir **depois** de abrir o teste.

## 10 Limitações

- n efetivo  $\approx$  223 animais e 93 estudos, não 1.115 linhas independentes.
- Desbalanceamento extremo (Grandvale).
- Classes raras de sexo e o status “Crescimento e Terminação”.
- Frações A/B idênticas: ou são a mesma variável mascarada duas vezes, ou o recorte colapsou as duas.
- ICC alto implica que um estudo novo pode deslocar o nível do MAPE de um jeito que covariáveis do animal não capturam (efeito de publicação / protocolo).
- Não olhamos o teste; generalização oficial da competição pode usar outro recorte.

## 11 O que fica amarrado

1. Validar por Estudo; nunca por linha.
2. Não usar Estudo como feature; país sim.
3. Baseline obrigatório: mediana de MAPE por modelo (e, no case, Modelo\_4 como campeão global).
4. Interação modelo empírico  $\times$  animal; dois estágios no log para o ML (patamar do animal + resíduo do empírico).
5. **Dualidade de alvos**. Na *competição* (MAPE contínuo), o baseline de mediana permanece competitivo: menor MAE no GroupKFold e robustez às caudas ( $R^2$  negativo nos lineares). No *case* (ranking do melhor empírico por animal), o **Ridge em dois estágios** superou o campeão do fold no LOSO e é o seletor a usar quando o teste for aberto.
6. Case: apostas da mediana local registradas acima (teste lacrado), com o Ridge como regra de ranking validada no LOSO.

Reprodução: na pasta do projeto–rgna.Rproj, Rscript nos scripts 01–03, python3 nos 04–05, e  
rmarkdown::render("relatorio/relatorio-eda.Rmd").